APRESENTAÇÃO DO PROBLEMA — MOMENTO 2 (M2)

Análise Transacional e Modelação Preditiva de Churn de Clientes no Comércio Eletrónico

Estudante: Francisco Oliveira	**UC:** Seminário de Sistemas e Aplicações (SSA)
Curso: Mestrado em Eng. Informática (MEINF - UFP)	**Docente:** Prof. Doutor Luís Borges Gouveia
Repositório Git: github.com/oshico/UFP_SSA	**Data:** Outubro 2026 | **Fase:** Definição M2

1. DEFINIÇÃO FORMAL E DELIMITAÇÃO DO PROBLEMA

No setor do comércio eletrónico retalhista, a retenção de compradores é o principal motor de rentabilidade a longo prazo. A aquisição de novos clientes envolve custos crescentes de marketing e publicidade (CAC), que frequentemente excedem as margens das primeiras transações. O fenómeno do *churn silencioso* — caracterizado pela cessação gradativa ou abrupta de compras por parte dos utilizadores sem aviso prévio — representa uma perda substancial de faturação. Este projeto aborda o problema formulando um modelo de apoio à decisão em R, capaz de processar históricos transacionais volumosos, converter transações multi-moeda através de uma API REST cambial, construir a matriz comportamental RFM (Recência, Frequência e Valor Monetário) e prever a probabilidade de inatividade/churn a 90 dias com recurso a técnicas de aprendizagem automática.

2. QUADRO DE PERGUNTAS ANALÍTICAS DE INVESTIGAÇÃO

ID	Pergunta Analítica	Variáveis Envolvidas	Técnica / Ação R
P1	Como variam os volumes de faturação e as frequências de encomenda ao longo dos trimestres e entre mercados geográficos?	InvoiceDate, Amount_EUR, Country	Agregação temporal em dplyr e mapas de calor em ggplot2.
P2	Qual a relação estatística entre o rácio de devoluções de produtos e a pontuação RFM dos clientes?	Return_Ratio, Recency_Days, Monetary_Total	Cruzamento de variáveis e *boxplots* comparativos por segmento.
P3	Existe diferença estatisticamente significativa no valor médio de compra entre clientes recorrentes e ocasionais?	Frequency_Orders, UnitPrice, Quantity	Testes de hipóteses estatísticos (Teste-t / ANOVA em R).
P4	É possível treinar um algoritmo de classificação em R para prever o *churn* a 90 dias com elevada sensibilidade?	Churn_90d (Target), RFM_Metrics, Return_Ratio	Regressão Logística / Árvores de Decisão com matriz de confusão e curvas ROC.

3. DICIONÁRIO DE DADOS COMPLETO (DATA DICTIONARY)

Nome do Atributo	Tipo de Dado	Origem	Descrição e Significado Funcional de Negócio
InvoiceNo	Texto (Categórico)	Kaggle CSV	Identificador único da fatura (prefixo 'C' indica cancelamento/devolução).
StockCode	Texto (Categórico)	Kaggle CSV	Código alfanumérico identificador do produto catalogado.
Description	Texto (Livre)	Kaggle CSV	Designação comercial e caraterísticas do artigo vendido.
Quantity	Inteiro (Contínuo)	Kaggle CSV	Unidades compradas (valores negativos representam devoluções).
InvoiceDate	Data/Hora (Temporal)	Kaggle CSV	Data e hora exata da emissão do documento transacional.
UnitPrice	Numérico (Contínuo)	Kaggle CSV	Preço unitário do produto na moeda original de faturação.
CustomerID	Inteiro (Categórico)	Kaggle CSV	Identificador único do cliente registado (tratamento de NAs).
Country	Texto (Categórico)	Kaggle CSV	País de residência ou entrega da encomenda internacional.
ExchangeRate	Numérico (Contínuo)	API REST JSON	Taxa de câmbio importada via Open Exchange Rates API.
Amount_EUR	Numérico (Contínuo)	Calculado (R)	Valor monetário convertido para Euros (Quantity * UnitPrice * Rate).
Recency_Days	Inteiro (Contínuo)	Calculado (RFM)	Número de dias decorridos desde a última compra do cliente.
Frequency_Orders	Inteiro (Contínuo)	Calculado (RFM)	Número total de faturas distintas emitidas pelo cliente.
Monetary_Total	Numérico (Contínuo)	Calculado (RFM)	Soma total acumulada de compras efetuadas pelo cliente em EUR.
Return_Ratio	Numérico (Proporção)	Calculado (R)	Rácio entre itens devolvidos e total de itens encomendados.
Churn_90d	Fator Binário (0/1)	Target (R)	Variável Alvo: 1 se Recência > 90 dias (Churn), 0 caso contrário (Ativo).

4. VALIDAÇÃO DOS CRITÉRIOS DE ELEGIBILIDADE FUC

Requisito do Guião / FUC	Métrica do Projeto	Validação
Dimensão do Dataset (>1.000 registos)	541.909 linhas transacionais e 4.372 clientes únicos	**Conforme (>500k)**
Diversidade Tipológica (6-8 variáveis)	15 variáveis (numéricas, categóricas, temporais e derivadas)	**Conforme (15 vars)**
Necessidade de Data Wrangling Real	Tratamento de devoluções ('C'), NAs no CustomerID, agregações RFM	**Conforme**
Consumo de Dados Externos (API)	Open Exchange Rates REST API via httr2/jsonlite em R	**Conforme (API REST)**
Reprodutibilidade e Governação Git	Repositório GitHub github.com/oshico/UFP_SSA com caminhos relativos	**Conforme**

5. ESTRUTURA E GOVERNAÇÃO DO REPOSITÓRIO GIT

Organização Modular do Projeto RStudio:

• data/raw/: Dataset bruto original (*Online Retail.csv*).
• data/processed/: Dataset transformado com métricas RFM e indicador de churn.
• R/: Scripts R modulares e comentados (*01_ecommerce_churn_analysis.R*).
• docs/report.qmd: Relatório reprodutível compilado em Quarto / R Markdown.
• README.md: Documentação completa do projeto, instruções de execução e declaração do repositório github.com/oshico/UFP_SSA.