APRESENTAÇÃO DO PROBLEMA — MOMENTO 2 (M2)

Análise Transacional e Modelação Preditiva de Churn de Clientes no Comércio Eletrónico

Estudante: Francisco Oliveira	**UC:** Seminário de Sistemas e Aplicações (SSA)
Curso: Mestrado em Eng. Informática (MEINF — UFP)	**Docente:** Prof. Doutor Luís Borges Gouveia
Repositório Git: github.com/oshico/UFP_SSA	**Data:** Outubro de 2026 | **Fase:** Definição M2

1. DEFINIÇÃO FORMAL E DELIMITAÇÃO DO PROBLEMA

No setor do comércio eletrónico retalhista, a retenção de compradores é o principal motor de rentabilidade a longo prazo. A aquisição de novos clientes envolve custos crescentes de marketing e publicidade (CAC), que frequentemente excedem as margens das primeiras transações. O fenómeno do *churn silencioso* — caracterizado pela cessação gradativa ou abrupta de compras por parte dos utilizadores sem aviso prévio — representa uma perda substancial de faturação. Este projeto aborda o problema formulando um modelo de apoio à decisão em R, capaz de processar históricos transacionais volumosos, converter transações multi-moeda através de uma API REST cambial, construir a matriz comportamental RFM (Recência, Frequência e Valor Monetário) e prever a probabilidade de inatividade/*churn* a 90 dias com recurso a técnicas de aprendizagem automática.

2. QUADRO DE PERGUNTAS ANALÍTICAS DE INVESTIGAÇÃO

ID	Pergunta Analítica	Variáveis Envolvidas	Técnica / Ação R
P1	Como variam os volumes de faturação e as frequências de encomenda ao longo dos trimestres e entre mercados geográficos?	`InvoiceDate, Amount_EUR, Country`	Agregação temporal em dplyr e mapas de calor em ggplot2.
P2	Qual a relação estatística entre o rácio de devoluções de produtos e a pontuação RFM dos clientes?	`Return_Ratio, Recency_Days, Monetary_Total`	Cruzamento de variáveis e *boxplots* comparativos por segmento.
P3	Existe diferença estatisticamente significativa no valor médio de compra entre clientes recorrentes e ocasionais?	`Frequency_Orders, UnitPrice, Quantity`	Testes de hipóteses estatísticos (Teste-t / ANOVA em R).
P4	É possível treinar um algoritmo de classificação em R para prever o *churn* a 90 dias com elevada sensibilidade?	`Churn_90d (Target), RFM_Metrics, Return_Ratio`	Regressão Logística / Árvores de Decisão com matriz de confusão e curvas ROC.

3. DICIONÁRIO DE DADOS COMPLETO (DATA DICTIONARY)

Nome do Atributo	Tipo de Dado	Origem	Descrição e Significado Funcional de Negócio
`InvoiceNo`	Texto (Categórico)	Kaggle CSV	Identificador único da fatura (prefixo 'C' indica cancelamento/devolução).
`StockCode`	Texto (Categórico)	Kaggle CSV	Código alfanumérico identificador do produto catalogado.
`Description`	Texto (Livre)	Kaggle CSV	Designação comercial e caraterísticas do artigo vendido.
`Quantity`	Inteiro (Contínuo)	Kaggle CSV	Unidades compradas (valores negativos representam devoluções).
`InvoiceDate`	Data/Hora (Temporal)	Kaggle CSV	Data e hora exata da emissão do documento transacional.
`UnitPrice`	Numérico (Contínuo)	Kaggle CSV	Preço unitário do produto na moeda original de faturação.
`CustomerID`	Inteiro (Categórico)	Kaggle CSV	Identificador único do cliente registado (tratamento de NAs).
`Country`	Texto (Categórico)	Kaggle CSV	País de residência ou entrega da encomenda internacional.
`ExchangeRate`	Numérico (Contínuo)	API REST JSON	Taxa de câmbio importada via Open Exchange Rates API.
`Amount_EUR`	Numérico (Contínuo)	Calculado (R)	Valor monetário convertido para Euros (Quantity * UnitPrice * Rate).
`Recency_Days`	Inteiro (Contínuo)	Calculado (RFM)	Número de dias decorridos desde a última compra do cliente.
`Frequency_Orders`	Inteiro (Contínuo)	Calculado (RFM)	Número total de faturas distintas emitidas pelo cliente.
`Monetary_Total`	Numérico (Contínuo)	Calculado (RFM)	Soma total acumulada de compras efetuadas pelo cliente em EUR.
`Return_Ratio`	Numérico (Proporção)	Calculado (R)	Rácio entre itens devolvidos e total de itens encomendados.
`Churn_90d`	Fator Binário (0/1)	Target (R)	**Variável Alvo:** 1 se Recência > 90 dias (Churn), 0 caso contrário (Ativo).

4. VALIDAÇÃO DOS CRITÉRIOS DE ELEGIBILIDADE FUC

Requisito do Guião / FUC	Métrica do Projeto	Validação
Dimensão do Dataset (>1.000 registos)	541.909 linhas transacionais e 4.372 clientes únicos	**Conforme (>500k)**
Diversidade Tipológica (6-8 variáveis)	15 variáveis (numéricas, categóricas, temporais e derivadas)	**Conforme (15 vars)**
Necessidade de Data Wrangling Real	Tratamento de devoluções ('C'), NAs no CustomerID, agregações RFM	**Conforme**
Consumo de Dados Externos (API)	Open Exchange Rates REST API via httr2/jsonlite em R	**Conforme (API REST)**
Reprodutibilidade e Governação Git	Repositório GitHub github.com/oshico/UFP_SSA com caminhos relativos	**Conforme**

5. ESTRUTURA E GOVERNAÇÃO DO REPOSITÓRIO GIT

Organização Modular do Projeto RStudio:

Ficheiro / Pasta	Função e Conteúdo
`data/raw/`	Dataset bruto original (Online Retail.csv).
`data/processed/`	Dataset transformado com métricas RFM e indicador de churn.
`R/`	Scripts R modulares e comentados (01_ecommerce_churn_analysis.R).
`docs/report.qmd`	Relatório reprodutível compilado em Quarto / R Markdown.
`README.md`	Documentação completa do projeto, instruções de execução e declaração do repositório github.com/oshico/UFP_SSA.