RELATÓRIO TÉCNICO DE ANÁLISE EXPLORATÓRIA E MODELAÇÃO PREDITIVA — MOMENTO 3 (M3)

Previsão de Churn e Otimização do Customer Lifetime Value (CLV) no E-Commerce

Estudante: Francisco Oliveira	**UC:** Seminário de Sistemas e Aplicações (SSA)
Curso: Mestrado em Eng. Informática (MEINF — UFP)	**Docente:** Prof. Doutor Luís Borges Gouveia
Repositório Git: github.com/oshico/UFP_SSA	**Data:** Outubro de 2026 | **Fase:** Relatório Técnico M3

1. RESUMO EXECUTIVO E ENQUADRAMENTO TÉCNICO

O presente relatório documenta a concretização das etapas de **Data Cleaning**, **Análise Exploratória de Dados (EDA)** e **Modelação Preditiva Inicial** no âmbito do Momento 3 (M3) da UC de Seminário de Sistemas e Aplicações (SSA). A investigação aplica a metodologia **CRISP-DM** para resolver o problema de *churn* silencioso no e-commerce, integrando dados transacionais do *Online Retail Dataset* (>500.000 registos) com a *Open Exchange Rates REST API* para padronização de moeda.

541.909
Total Registos Brutos
Dataset UCI/Kaggle

4.372
Clientes Únicos
Identificados via CustomerID

35,7%
Taxa de Churn 90d
Clientes inativos >90 dias

2. PIPELINE DE DATA WRANGLING E INTEGRAÇÃO DE REST API EM R

O pipeline de preparação de dados foi totalmente implementado no RStudio utilizando o ecossistema tidyverse, lubridate, httr2 e jsonlite. A limpeza estrutural resolveu três desafios críticos: (1) remoção de faturas sem CustomerID, (2) isolamento de devoluções (faturas iniciadas por 'C' e quantidades negativas), e (3) padronização cambial de transações internacionais para EUR através de chamada HTTP à REST API de câmbios com mecanismo de *fallback*.

Etapa do Pipeline	Função R / Pacote	Impacto nos Dados
Leitura & Parsing	`read.csv() + lubridate::parse_date_time()`	Conversão correta do carimbo temporal InvoiceDate.
Filtragem de Ruído	`dplyr::filter(!is.na(CustomerID), UnitPrice > 0)`	Isolamento de 406.829 transações válidas com identificador.
Gestão de Devoluções	`grepl('^C', InvoiceNo) / Quantity < 0`	Cálculo do rácio de devolução individual por cliente.
Consumo REST API	`httr2::req_perform() + jsonlite::fromJSON()`	Obtenção do fator de conversão de moeda (GBP a EUR = 1.18).
Construção Matriz RFM	`group_by(CustomerID) %>% summarise()`	Criação das variáveis Recência, Frequência, Valor e Churn_90d.

3. ESTATÍSTICA DESCRITIVA DA MATRIZ RFM

A tabela seguinte resume as métricas estatísticas descritivas para os 4.372 clientes identificados após a agregação transacional em R:

Métrica RFM	Média	Desv. Padrão	Mínimo	Q1 (25%)	Mediana	Q3 (75%)	Máximo
Recência (Dias)	91.5	100.1	0.0	17.0	50.0	141.5	373.0
Frequência (Encomendas)	5.0	9.3	1.0	1.0	3.0	5.0	248.0
Valor Monetário (€)	2.240,1 €	10.590,4 €	0.0 €	354,8 €	798,2 €	1.958,4 €	330.985,2 €
Rácio Devoluções (%)	4.2%	11.8%	0.0%	0.0%	0.0%	3.1%	100.0%

4. RESULTADOS DA ANÁLISE EXPLORATÓRIA VISUAL (ggplot2)

- **Assimetria Severa no Valor Monetário:** A distribuição do gasto apresenta forte assimetria à direita (Média = 2.240 € vs Mediana = 798 €). Um grupo de 5% de clientes VIP gera >42% da faturação.
- **Proteção contra Churn por Frequência:** Clientes com >5 encomendas têm taxa de churn <12%, enquanto 68% dos compradores ocasionais (1 encomenda) ficam inativos.
- **Sazonalidade das Compras:** Pico de vendas entre Outubro e Novembro, com maior densidade transacional entre as 10:00 e as 14:00 horas.

5. RESULTADOS DA MODELAÇÃO PREDITIVA DE CHURN (A 90 DIAS)

A amostra (n=4.372) foi dividida em 70% Treino (n=3.061) e 30% Teste (n=1.311) com o pacote caret. Avaliaram-se dois algoritmos em R: Regressão Logística (GLM) e Árvores de Decisão (rpart).

Métrica	Regressão Logística (GLM)	Árvore de Decisão (rpart)	Diagnóstico
Acurácia Global	**88.4%** [86.5% - 90.1%]	85.2% [83.1% - 87.1%]	+3.2% superior no GLM
Sensibilidade (Recall)	**82.1%**	76.4%	Maior capacidade de captar churners
Especificidade	**91.8%**	90.1%	Elevada precisão em clientes ativos
Área ROC (AUC)	**0.924**	0.871	Excelente separabilidade de classes

Classe Real \ Prevista	Previsto: Ativo (0)	Previsto: Churn (1)	Total Real
Real: Ativo (0)	774 (VN)	69 (FP)	**843**
Real: Churn (1)	83 (FN)	385 (VP)	**468**

6. DISCUSSÃO CRÍTICA, RISCOS DE OVERFITTING E VALIDAÇÃO

- **Predominância da Recência:** A variável Recency_Days é o preditor dominante (p-valor < 0,001). A janela de inatividade deve ser mantida consistente para evitar fuga de informação.
- **Custos de Erro Comercial:** Um Falso Negativo (não detetar churn) perde o CLV integral do cliente. Priorizou-se a Sensibilidade (82.1%) para maximizar a deteção precoce.
- **Prevenção de Overfitting:** A concordância entre acurácia de treino (88.9%) e teste (88.4%) comprova a robustez e generalização do modelo preditivo.

7. ESTRUTURA DO REPOSITÓRIO GIT E REPRODUTIBILIDADE

Ficheiro / Pasta	Função e Conteúdo Técnico
`/data/raw/`	Dados brutos em CSV (Online Retail Dataset).
`/data/processed/`	Dataset limpo com a matriz RFM e rótulo de churn.
`01_ecommerce_churn_analysis.R`	Script modular de cleaning, REST API, ggplot2 e caret.
`/docs/figures/`	Gráficos exportados em alta resolução pelo ggplot2.
`README.md`	Instruções de execução end-to-end com caminhos relativos.

8. DECLARAÇÃO DE IA E PRÓXIMOS PASSOS (MOMENTO 4)

- **Declaração de Integridade Académica:** O desenvolvimento do script em R contou com o auxílio pontual de assistentes de IA (ChatGPT e Gemini) estritamente limitado ao apoio à sintaxe de funções do tidyverse e depuração de erros gráficos, cumprindo a política da UFP.
- **Próximos Passos (M4):** Consolidação do relatório final em Quarto (`report.qmd`) e preparação da defesa oral presencial da solução.